

ENSAE

Dakar — ISEP2

23

indicateurs

14

régions

5

sources

Construction d'un Indice Composite Robuste pour les 14 Régions du Sénégal

Thème 6 • Traitement Statistique avec R • ISEP2

Boye DIBA

expose06DibaBoye2026ENSAE

Définitions & Objectifs

Les données

Étape 1 — Audit des indicateurs

Étape 2 — Normalisation

Étape 3 — ACP

Étape 4 — Construction de l'indice

Étape 5 — Analyse de sensibilité

Résultats & Implications

Conclusion

Définitions & Objectifs

Indicateur

Mesure chiffrée d'un aspect du développement. *Ex.* : taux d'alphabétisation (%), mortalité infantile (pour 1000), PIB régional (Mds FCFA).

Indice composite

Score unique qui **combine plusieurs indicateurs** en un seul chiffre. **Ex.** : **IDH** (PNUD) · **Doing Business** (BM) · **IDISA** (genre, Afrique)

Normalisation

Mise à la **même échelle** de tous les indicateurs. Un PIB en milliards et un taux en % ne peuvent pas être additionnés tels quels.

ACP — Composantes Principales

Résume 23 indicateurs en quelques **axes indépendants** captant l'essentiel de la variabilité.

Valeur propre λ

Quantité d'information d'un axe ACP.
Critère de Kaiser : retenir $\lambda \geq 1$.

Pondération

Attribution de poids différents selon l'**importance** jugée ou statistique des indicateurs.

AHP

Analytic Hierarchy Process : pondération par **comparaison par paires** entre dimensions. Jugement d'expert structuré.

ρ de Spearman

Corrélation entre deux **classements**.
 $\rho = 1$: identiques • $\rho = 0$: aucun lien •
 $\rho < 0$: inversés

Robustesse

Classement **stable** quel que soit le choix méthodologique retenu.

Objectifs de l'exposé

Objectif général

Construire un **indice composite de développement local** pour les 14 régions du Sénégal et évaluer sa robustesse aux choix méthodologiques.

Objectifs spécifiques

1. **Auditer** les 23 indicateurs : qualité, redondances, valeurs manquantes
2. **Comparer** 3 méthodes de normalisation (Min-Max, Z-score, Centile)
3. **Identifier** les dimensions latentes via l'ACP
4. **Construire** 3 indices avec des systèmes de pondération différents
5. **Tester** la robustesse via la corrélation de Spearman

À retenir

Ce travail **teste une méthode** et examine dans quelle mesure les résultats en dépendent.

Le Sénégal en chiffres clés

- **IDH : 0,51** — rang 168/193 (PNUD 2023)
- Pauvreté : **37,8%** (EHCVM 2021)
- Dakar : **55% du PIB** sur **0,3%** du territoire
- Kédougou : riche en or, **IDH le plus faible**
- Pauvreté rurale : **57,3%** vs 26,1% urbain
- Gradient **Nord-Ouest / Sud-Est** persistant

Un déséquilibre structurel

Déficit d'investissement sur certaines régions
— pas un manque de ressources.

Pourquoi un indice composite ?

Un seul indicateur ne suffit pas :

- Alphabétisation : oublie la santé
- PIB : masque la distribution
- IDH officiel : ignore l'infrastructure

⇒ **23 indicateurs** en 5 dimensions pour une mesure globale et comparable.

Problème & Question centrale

Le problème

Pour orienter les investissements publics, il faut **classer objectivement** les 14 régions. Or tout indice repose sur des **choix méthodologiques** susceptibles de modifier le classement.

Question centrale


*Le classement dépend-il des **choix méthodologiques** ou reflète-t-il la réalité ?*

Enjeu concret

Si le classement varie selon la méthode, c'est le statisticien — et non les faits — qui oriente la politique publique.

Les données

Les données : 23 indicateurs, 14 régions, 5 sources



Pourquoi ces poids ?

Calibrés par **jugement d'expert (AHP, Saaty 1980)** : éducation/économie prioritaires au Sénégal ; démographie à 10% (caractérise sans discriminer). Validés par analyse de sensibilité ($\rho_S > 0,99$).

Sources : ANSD/RGPH 2023 · EHCVM 2021
PNUD · Banque Mondiale · OpenAfrica

Pourquoi des données simulées ?

Microdonnées régionales **non toutes publiques** : RGPH 2023 partiel, EHCVM accès restreint, IDH subnational agrégé.

⇒ Simulation **calibrée** sur rapports officiels (`set.seed(2026)`).

Pipeline `construction_base.R`

1. **Charge** 5 fichiers sources bruts
2. **Diagnostic** : NA, doublons, encodages
3. **Nettoie** : noms, unités, espaces
4. **Merge** progressif par clé `region`
5. **Sauvegarde** `donnees_regions.csv`

5 difficultés documentées dans le script

- **Noms** : "Saint Louis" → "Saint-Louis" ; "Sedhiou" → "Sédhiou" (ANSD)
- **2 NA** : `revenu_moy` manquant (Kaffrine, Sédhiou) — imputés par la médiane
- **Doublon** : ligne Dakar en double dans la source Banque Mondiale
- **Unité** : PIB en millions USD → milliards FCFA ($\times 600 \div 1000$)
- **Préfixe** : "Région de Dakar" → "Dakar" (source PNUD)

Étape 1 — Audit des indicateurs

3 risques sans audit

1. **Redondance** : double comptage (ex. IDH + alphabétisation)
2. **Données manquantes** : biaise tous les calculs
3. **Faible discrimination** : indicateur quasi-constant $\Rightarrow$ nul

3 outils d'audit

1. Taux de valeurs manquantes — seuil $> 20\%$
2. Coefficient de variation (CV) — seuil $< 5\%$
3. Corrélation de Pearson — seuil $|r| > 0,95$


Résultat

0 valeur manquante | 0 paire redondante

$\Rightarrow$ Les **23 indicateurs** sont conservés.

Matrice de corrélation — Audit de redondance

Matrice de corrélation des 23 indicateurs



Interprétation

Les blocs roses confirment la cohérence interne de chaque dimension. Aucune paire ne dépasse $|r| = 0,95$: les 23 indicateurs mesurent des réalités **distinctes** et sont tous conservés pour la construction de l'indice.

Étape 2 — Normalisation

Les 3 méthodes de normalisation

Min-Max

$$x^* = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

- + Valeurs dans $[0, 1]$
- + Intuitive
- Sensible aux extrêmes
(Dakar tire l'échelle vers le haut)

Z-score

$$z = \frac{x - \bar{x}}{s_x}$$

- + Robuste aux valeurs extrêmes
- + Utilisée pour l'ACP
- Peut être négative
- Moins intuitive

Centile

$$c = \frac{\text{rang}(x)}{n}$$

- + Très robuste
- + Élimine les extrêmes
- Perd l'amplitude des écarts


Étape préalable : orientation des indicateurs

5 indicateurs négatifs (valeur élevée = mauvais) : mortalité, pauvreté, chômage, emploi informel, fécondité. Multipliés par -1 pour que "score élevé = bonne situation" soit universel.

Impact des méthodes sur le classement

Impact des 3 méthodes de normalisation sur le classement

Indice équi pondéré — 14 régions (classées par score Min-Max décroissant)



Interprétation

Les trois courbes sont quasi-superposées : le choix de normalisation **ne modifie pas** le classement des 14 régions. Ce signal robuste signifie que les disparités régionales au Sénégal sont suffisamment marquées pour s'imposer quelle que soit l'échelle.

Min-Max retenue pour la suite (scores dans $[0, 1]$, lisibles directement).

Étape 3 — ACP

ACP : principe et objectifs dans ce projet

Qu'est-ce que l'ACP ?

Transforme **23 indicateurs corrélés** en un nombre réduit d'**axes indépendants**, chacun capturant une part de la variabilité totale.

Dans ce projet, l'ACP sert à :

1. Réduire 23 indicateurs à **quelques axes** synthétiques
2. Visualiser régions et indicateurs (**biplot**)
3. Calculer des **poids objectifs** (variance expliquée)


Paramétrage

- **Données** : indicateurs z-score
- `scale.unit=FALSE` : pas de double standardisation
- **Kaiser** : retenir $\lambda \geq 1$
- $n = 14$ régions, $p = 23$ indicateurs

Remarque

$n = 14$ régions $\Rightarrow$ 13 axes max.
L'ACP réduit efficacement la dimensionnalité.


Éboulis des valeurs propres — Combien d'axes retenir ?



Interprétation

L'Axe 1 capte ~**70-80%** de la variance totale : il traduit le gradient global de développement qui sépare **Dakar** du reste du pays. Le coude prononcé après l'Axe 1 justifie le critère de Kaiser — **2 axes retenus** couvrant $> 95\%$ de l'information.

Biplot ACP — Régions et indicateurs ensemble



Interprétation

Dakar est isolée à l'extrême droite de l'Axe 1 : son avance sur toutes les dimensions est structurelle. À l'opposé, **Kédougou, Kolda et Sédhiou** forment un groupe de régions défavorisées. Les flèches longues (électricité, revenu, éducation) identifient les indicateurs **structurants** du développement régional.

Dimensions latentes identifiées

					Dimension	Axe 1	Axe 2	Axe 3
Axe	λ	Var.	Cum.	Thème	Éducation	17.7%	13.8%	3.5%
Dim. 1	20.03	93.8%	93.8%	Hum.glob.	Santé	18%	7.7%	1.1%
Dim. 2	1.01	4.7%	98.5%	Infra.	Économie	21.6%	29.4%	1.7%
Dim. 3	0.19	0.9%	99.4%	Démo.	Infrastructure	18.2%	5.4%	0.8%
					Démographie	24.4%	43.7%*	92.9%*
Gras*: dom. ($\geq 30\%$) Ital.: mod. ($\geq 15\%$)								

Interprétation des 3 dimensions latentes

- **Dim. 1 — Dév. humain** (~70-80% variance) : sépare **Dakar/Thiès** (éducation, santé, revenus) du reste
- **Dim. 2 — Infrastructure** : oppose régions **bien desservies** (routes, internet) aux régions enclavées
- **Dim. 3 — Démographie** : distingue zones **jeunes/rurales** (fécondité, agriculture) des zones urbanisées

Étape 4 — Construction de l'indice

Les 3 systèmes de pondération

Système 1

Équipondération

$$w_i = \frac{1}{23} \text{ pour tout } i$$

Simple, transparent

Choix politique implicite :
donne autant d'importance
à la densité routière qu'à

la mortalité infantile

Système 2

Pondération ACP

$$w_k \propto \lambda_k$$

Basé sur les données
Objectif

Peut sur-pondérer l'Axe 1
si très dominant

Système 3 — RETENU

Pondération AHP

Éduc/Éco **25%**

Santé/Infra **20%**

Démo **10%**

Raisonnement par
dimensions


Subjectif mais justifié

et testé en sensibilité

Piège fondamental

L'équipondération *semble* neutre, mais c'est un **choix politique implicite** :
mortalité infantile = superficie agricole ? Ce n'est pas une neutralité — c'est une
décision à expliciter et défendre.

Profil multidimensionnel des régions




Interprétation

Chaque région présente un profil **déséquilibré** selon les 5 dimensions. **Kédougou**, riche en ressources minières, affiche un faible score économique — illustration du *paradoxe des ressources*. Aucun indicateur seul ne suffit : l'indice composite agrège ces dimensions pour un classement **équitable**.

Étape 5 — Analyse de sensibilité

Stabilité des classements selon la méthode



Interprétation

Les trajectoires quasi-horizontales montrent que le **rang de chaque région reste stable** quelle que soit la méthode. Les disparités régionales au Sénégal sont suffisamment marquées pour s'imposer indépendamment des choix de pondération : **l'indice est robuste.**

Robustesse confirmée — Corrélations de Spearman


Comparaison	ρ de Spearman	Interprétation
Équipondération vs ACP	0.996	Convergence très forte — quasi-identiques
Équipondération vs AHP	0.996	Convergence très forte — quasi-identiques
ACP vs AHP	1.000	Convergence quasi-parfaite

Interprétation

Avec $\rho_S > 0,99$ sur les trois paires et un écart maximal d'**un seul rang**, les trois méthodes convergent vers le même classement. Cela confirme que l'indice reflète une **réalité socioéconomique structurelle** au Sénégal, et non un artefact méthodologique.

Résultats & Implications


Classement final des 14 régions du Sénégal



Interprétation

Dakar domine avec un score de 0,871, soit plus du double de **Thiès** (2^e). La majorité des régions se situe **sous la moyenne nationale** (ligne pointillée), révélant un déséquilibre structurel concentré dans le Sud et le Centre-Est du pays.

Cartographie — Gradient géographique du développement



Interprétation

La carte matérialise le **gradient Nord-Ouest / Sud-Est** documenté par l'ANSD : les régions côtières et du fleuve Sénégal (Dakar, Thiès, Saint-Louis) concentrent les scores les plus élevés, tandis que la **Casamance et le Sénégal Oriental** restent en retard structurel.

Top 3 — Régions les plus développées

1. **Dakar (0,871)** — Capitale. Score $> 2 \times$ la 2^e région. Services, emplois formels, universités.
2. **Thiès (0,519)** — 2^e pôle économique, routes denses, phosphates.
3. **Saint-Louis (0,462)** — Ancienne capitale, université, agriculture irriguée.

Bottom 3 — Régions prioritaires

12. **Kolda (0,164)** — Enclavement, déficit de services
13. **Sédhiou (0,161)** — Région jeune, sous-équipée
14. **Kédougou (0,129)** — Riche en or, mais IDH le plus faible — *paradoxe des ressources*.

Gradient documenté

Cohérent avec tous les travaux ANSD et PNUD sur les disparités régionales au Sénégal.

Conclusion

Pièges méthodologiques identifiés

Piège #1 — Orientation

5 indicateurs inversés ($\times - 1$) avant normalisation. Sans cette étape, on **récompense** les régions à forte mortalité infantile.

Piège #2 — Min-Max sensible

Dakar ($\approx 0,87$) tire l'échelle vers le haut et **compresse** les écarts entre les autres régions.

Piège #3 — Équipondération politique

Poids égaux **n'est pas neutre** : donner le même poids à la mortalité infantile et à la superficie agricole est un choix implicite.

Piège #4 — Robustesse $\neq$ Vérité

$\rho_S > 0,99$ confirme la **convergence des méthodes**, pas la validité des données. L'audit externe reste indispensable.

Un classement variable selon la méthode est un résultat scientifique

Il doit être **reporté et interprété honnêtement** — pas caché.

Bilan — Ce que nous avons montré

Démarche réalisée

- **23 indicateurs** audités (0 manquant, 0 redondant)
- **3 normalisations** : Min-Max, Z-score, Centile
- **ACP** : 2 axe(s) — 98.5% variance cumulée
- **3 indices** : équipondéré, ACP, AHP
- **Robustesse** : $\rho_S = 0.996$ (Équi vs AHP)

Limites

Données simulées · Poids AHP subjectifs · Pas de panel temporel

Réponse à la question centrale

Le classement **ne dépend pas** des choix méthodologiques :

$\rho_S > 0,99$ — variation max. = **1 rang**.

⇒ Le gradient **Nord-Ouest / Sud-Est** prime sur les choix techniques.

Merci pour votre attention !

Questions & Discussion

ENSAE Dakar — ISEP2 / 2025-2026 · Traitement Statistique avec R

expose06DibaBoye2026ENSAE