

ENSAE

Dakar — ISEP2

23

indicateurs

14

régions

5

sources

Construction d'un Indice Composite Robuste pour les 14 Régions du Sénégal

Thème 6 • Traitement Statistique avec R • ISEP2

Boye DIBA

expose06DibaBoye2026ENSAE

Définitions & Objectifs

Contexte & Données

Étape 1 — Audit des indicateurs

Étape 2 — Normalisation

Étape 3 — ACP

Étape 4 — Construction de l'indice

Étape 5 — Analyse de sensibilité

Résultats & Implications

Conclusion

Définitions & Objectifs

Indicateur

Mesure chiffrée d'un aspect du développement. *Ex.* : taux d'alphabétisation (%), mortalité infantile (pour 1000), PIB régional (milliards FCFA).

Indice composite

Score unique qui **combine plusieurs indicateurs** en un seul chiffre pour résumer une situation multidimensionnelle. **Exemples** : **IDH** (PNUD) — Éducation + Santé + Revenus • **Doing Business** (Banque Mondiale) • **IDISA** — Inégalités de genre en Afrique

Normalisation

Mise à la **même échelle** de tous les indicateurs pour les rendre comparables et additionnables. *Pourquoi ?* Un PIB en milliards et un taux en % ne peuvent pas être additionnés tels quels.

ACP — Composantes Principales

Résume 23 indicateurs en quelques **axes indépendants** captant l'essentiel de la variabilité.

Valeur propre λ

Quantité d'information d'un axe ACP.
Critère de Kaiser : retenir $\lambda \geq 1$.

Pondération

Attribution de poids différents selon l'**importance** jugée ou statistique des indicateurs.

AHP

Analytic Hierarchy Process : pondération par **comparaison par paires** entre dimensions. Jugement d'expert structuré.

ρ de Spearman

Corrélation entre deux **classements**.
 $\rho = 1$: identiques • $\rho = 0$: aucun lien •
 $\rho < 0$: inversés

Robustesse

Classement **stable** quel que soit le choix méthodologique retenu.

Objectifs de l'exposé

Objectif général

Construire un **indice composite de développement local** pour les 14 régions du Sénégal et évaluer sa robustesse aux choix méthodologiques.

Objectifs spécifiques

1. **Auditer** les 23 indicateurs : qualité, redondances, valeurs manquantes
2. **Comparer** 3 méthodes de normalisation (Min-Max, Z-score, Centile)
3. **Identifier** les dimensions latentes du développement via l'ACP
4. **Construire** 3 indices avec des systèmes de pondération différents
5. **Tester** la robustesse via l'analyse de sensibilité (corrélation de Spearman)

À retenir

Ce travail ne produit pas des statistiques officielles : il **teste une méthode** et examine dans quelle mesure les résultats en dépendent.

Contexte

Le Sénégal présente des inégalités régionales fortes. **Dakar** $\approx$ **55% du PIB** sur 0,3% du territoire — IDH national : **0,51** (rang 168/193, PNUD 2023) — Pauvreté : **37,8%** (EHCVM 2021).

Le problème

Pour orienter les investissements publics, il faut **classer objectivement** les 14 régions. Mais tout indice repose sur des **choix méthodologiques** (normalisation, pondération) qui peuvent influencer le classement et les décisions politiques.

Question centrale

*Le classement des 14 régions dépend-il des **choix méthodologiques** ou de la réalité socioéconomique ?*

Contexte & Données

Portrait des inégalités

- **14 régions** aux profils très contrastés
- Dakar : **55% du PIB** sur 0,3% du territoire
- Kédougou : riche en or, mais IDH le plus faible
- **Sud-Est** (Kolda, Sédhiou) systématiquement défavorisé
- Pauvreté rurale : **57,3%** vs 26,1% urbain

Un gradient persistant

Inégalité Nord-Ouest / Sud-Est **structurelle** : déficit d'investissement public, pas un manque de ressources.


Pourquoi un indice composite ?

Un seul indicateur est insuffisant :

- Alphabétisation seul : néglige la santé
- PIB seul : masque la distribution
- IDH : ignore l'infrastructure

⇒ **23 indicateurs** en 5 dimensions.

Les données : 23 indicateurs, 14 régions, 5 sources



Sources : ANSD/RGPH 2023 · EHCVM 2021 · IDH sous-national PNUD · Banque Mondiale DataBank · OpenAfrica

Justification des données simulées

Contexte de disponibilité

Les données régionales exhaustives ne sont pas toutes accessibles gratuitement au moment de ce travail. Le RGPH 2023 n'est que partiellement publié. Les microdonnées de l'EHCVM sont sous accès restreint.

Garanties de réalisme

- Ordres de grandeur calés sur les **rapports officiels ANSD** disponibles
- Le gradient **Nord-Ouest / Sud-Est** est respecté (documenté dans la littérature)
- **Dakar** : meilleurs scores urbains — **Kédougou** : scores les plus faibles
- Simulation **reproductible** et versionnée dans GitHub (fichier `donnees_regions.csv`)

Objectif pédagogique

Ce TP teste une **méthode**, pas des statistiques officielles. Les tendances sont réalistes et la robustesse reste valide.

Étape 1 — Audit des indicateurs

Pourquoi auditer ?

3 risques sans audit

1. **Redondance** : si deux indicateurs mesurent la même chose, on la comptabilise deux fois (ex. IDH et alphabétisation)
2. **Données manquantes** : un indicateur incomplet biaise tous les calculs
3. **Faible discrimination** : si toutes les régions ont la même valeur, l'indicateur n'apporte aucune information

3 outils d'audit utilisés


1. **Taux de valeurs manquantes** — seuil d'exclusion : $> 20\%$
2. **Coefficient de variation (CV)** — seuil d'exclusion : $< 5\%$ (indicateur quasi-constant)
3. **Corrélation de Pearson** — seuil de redondance : $|r| > 0,95$

Résultat

0 valeur manquante | 0 paire redondante
⇒ Les **23 indicateurs** sont conservés.

Matrice de corrélation — Audit de redondance

Matrice de corrélation des 23 indicateurs



Interprétation

Les **blocs rouges** révèlent des corrélations positives attendues au sein de chaque dimension (ex. éducation + IDH). Aucune paire n'atteint $|r| > 0,95$: **pas de redondance critique**. Les indicateurs de différentes dimensions sont peu corrélés (blanc) : chaque dimension apporte une information distincte.

Étape 2 — Normalisation

Les 3 méthodes de normalisation

Min-Max

$$x^* = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

- + Valeurs dans $[0, 1]$
- + Intuitive
- Sensible aux extrêmes
(Dakar tire l'échelle vers le haut)

Z-score

$$z = \frac{x - \bar{x}}{s_x}$$

- + Robuste aux valeurs extrêmes
- + Utilisée pour l'ACP
- Peut être négative
- Moins intuitive

Centile

$$c = \frac{\text{rang}(x)}{n}$$

- + Très robuste
- + Élimine les extrêmes
- Perd l'amplitude des écarts


Étape préalable obligatoire : orientation des indicateurs

5 indicateurs ont un sens négatif (valeur élevée = mauvais résultat) : mortalité infantile, pauvreté, chômage, emploi informel, fécondité. Ils sont multipliés par -1 avant normalisation pour que "score élevé = bonne situation" soit universel.

Impact des méthodes sur le classement

Comparaison de l'impact des 3 méthodes de normalisation

Indice équipondéré — 14 régions du Sénégal (classées par score Min-Max décroissant)



Interprétation

Les trois courbes sont **quasi-superposées** : le choix de la méthode de normalisation ne change pas significativement le classement. Le signal est robuste. La Min-Max est retenue pour la suite car elle produit des scores directement interprétables entre 0 et 1.

Étape 3 — ACP

ACP : principe et objectifs dans ce projet

Qu'est-ce que l'ACP ?

Transforme **23 indicateurs corrélés** en un nombre réduit d'**axes indépendants**, chacun capturant une part de la variabilité totale.

Dans ce projet, l'ACP sert à :

1. Réduire 23 indicateurs à **quelques axes** synthétiques
2. Visualiser régions et indicateurs (**biplot**)
3. Calculer des **poids objectifs** (variance expliquée)


Paramétrage

- **Données** : indicateurs z-score
- `scale.unit=FALSE` : pas de double standardisation
- **Kaiser** : retenir $\lambda \geq 1$
- $n = 14$ régions, $p = 23$ indicateurs

Remarque

$n = 14$ régions $\Rightarrow$ 13 axes max.
L'ACP réduit efficacement la dimensionnalité.


Éboulis des valeurs propres — Combien d'axes retenir ?



Interprétation du screeplot

L'Axe 1 capture à lui seul **environ 70-80%** de la variance totale : c'est la **dimension dominante** du développement au Sénégal — un gradient global qui sépare les régions développées des régions défavorisées. Le "coude" prononcé après l'Axe 1 confirme que les axes suivants apportent beaucoup moins d'information. Les axes retenus (valeur propre ≥ 1) expliquent ensemble $> 95\%$ de la variabilité.

Biplot ACP — Régions et indicateurs ensemble



Comment lire ce biplot ?

Points (régions) : une région à droite sur l'Axe 1 = bien développée. À gauche = défavorisée. **Flèches (indicateurs) :** une longue flèche vers la droite = cet indicateur contribue fortement au développement. Dakar (extrême droite) est nettement isolée. Kédougou, Kolda, Sédhiou sont à l'opposé.

Dimensions latentes identifiées

Table 1: Les 3 premiers axes de l'ACP

Axe	Val.\,pr.	Var.	Cum.	Interprétation
Dim. 1	20.03	93.8%	93.8%	Développement humain global (éducation + santé + revenus + accès services)
Dim. 2	1.01	4.7%	98.5%	Infrastructure et connectivité (routes, internet, électricité)
Dim. 3	0.19	0.9%	99.4%	Structure démographique (fécondité, urbanisation, emploi féminin)

Message clé

L'**Axe 1** domine : le développement sénégalais est **unidimensionnel**. Les régions s'alignent de Dakar à Kédougou. Les Axes 2-3 révèlent des nuances : infrastructure vs revenus.

Étape 4 — Construction de l'indice

Les 3 systèmes de pondération

Système 1

Équipondération

$$w_i = \frac{1}{23} \text{ pour tout } i$$

Simple, transparent

Choix politique implicite :
donne autant d'importance
à la densité routière qu'à

la mortalité infantile

Système 2

Pondération ACP

$$w_k \propto \lambda_k$$

Basé sur les données
Objectif

Peut sur-pondérer l'Axe 1

si très dominant

Système 3

Pondération AHP

Éduc/Éco **25%**

Santé/Infra **20%**

Démo **10%**


Raisonnement par
dimensions

Subjectif mais justifié

Piège fondamental

L'équipondération *semble* neutre, mais elle constitue en réalité un **choix politique implicite** : elle suppose que la mortalité infantile est aussi importante que la superficie agricole. Ce n'est pas une neutralité — c'est une décision qui mérite d'être explicitée et défendue.

Profil multidimensionnel des régions




Interprétation

Profil de chaque région en 5 dimensions. Les premières régions (gauche) ont des barres hautes. Certaines ont un profil **déséquilibré** : forte démographie, faible économie — d'où la nécessité d'un indice composite.

Étape 5 — Analyse de sensibilité

Stabilité des classements selon la méthode



Comment lire ce graphique ?

Chaque ligne représente une région. Une ligne **horizontale** = le classement de cette région ne change pas selon la méthode. Une ligne **inclinée ou croisée** = le classement est instable. Ici, les lignes sont quasi-horizontales : **le classement est très stable**, ce qui valide la robustesse de l'indice.

Robustesse confirmée — Corrélations de Spearman

Table 2: Corrélations de rang entre les 3 méthodes de pondération

Comparaison	ρ de Spearman	Interprétation
Équipondération vs ACP	0.996	Convergence très forte — quasi-identiques
Équipondération vs AHP	0.996	Convergence très forte — quasi-identiques
ACP vs AHP	1.000	Convergence quasi-parfaite

Interprétation


Rappel : $\rho = 1$ = classements identiques. Ici, $\rho > 0,99$ pour toutes les comparaisons. La variation maximale d'une région entre deux méthodes est de **1 rang**. Autrement dit, une région classée 5^e par une méthode sera au pire 6^e par une autre.

⇒ **L'indice est robuste : la réalité socioéconomique prime sur les choix méthodologiques.**

Résultats & Implications

Classement final des 14 régions du Sénégal

Indice composite de développement — Pondération AHP




Lecture du graphique

Les régions sont classées du score le plus faible (bas) au plus élevé (haut). La ligne pointillée or représente la **moyenne nationale**. La moitié des régions est en dessous — déséquilibre tiré par Dakar vers le haut.

Cartographie — Gradient géographique du développement

Gradient géographique — Sénégal (score AHP [0-1])



Lecture de la carte

La **taille et la couleur** de chaque bulle représentent le score AHP. **Rose vif = mieux développé** (Dakar, nord-ouest). **Rouge foncé = défavorisé** (Kédougou, Kolda, Sédhiou au sud-est). Le **gradient géographique** Nord-Ouest / Sud-Est est parfaitement visible.

Top 3 — Régions les plus développées

1. **Dakar (0,871)** — Capitale. Concentration de services, d'universités, d'emplois formels et d'infrastructures sans égal. Son score est plus du double de la 2^e région.
2. **Thiès (0,519)** — 2^e pôle économique, réseau routier dense, industrie phosphatière.
3. **Saint-Louis (0,462)** — Ancienne capitale, université, agriculture irriguée du delta.

Bottom 3 — Régions prioritaires

12. **Kolda (0,164)** — Enclavement, déficit de services
13. **Sédhiou (0,161)** — Région jeune, sous-équipée
14. **Kédougou (0,129)** — La plus isolée. Riche en or et biodiversité, mais le plus faible IDH du pays — *paradoxe des ressources naturelles*.

Gradient documenté

Ce résultat est cohérent avec tous les travaux de l'ANSD et du PNUD sur les disparités régionales au Sénégal.

Conclusion

Pièges méthodologiques identifiés

Piège #1 — Orientation des indicateurs

5 indicateurs doivent être inversés ($\times - 1$) avant normalisation. Oublier cette étape revient à **récompenser** les régions où la mortalité infantile est la plus élevée.

Piège #2 — Sensibilité Min-Max

La normalisation Min-Max est **sensible aux valeurs extrêmes**. Dakar (score $\approx 0,87$) tire toute l'échelle vers le haut, compressant les écarts entre les autres régions.

Piège #3 — Équipondération = choix politique

Poids égaux n'est **pas une neutralité** : c'est un choix implicite de donner la même importance à chaque indicateur, quel que soit son impact sur le bien-être.

Piège #4 — Robustesse $\neq$ Vérité

$\rho_S > 0,99$ confirme la **convergence des méthodes** entre elles, pas la validité des données simulées. La robustesse interne ne dispense pas d'un audit externe.

Un classement qui change selon la méthode n'est pas un problème à cacher
C'est un **résultat scientifique** qui doit être reporté et interprété honnêtement.

Démarche réalisée

- **23 indicateurs** audités (0 manquant, 0 redondant)
- **3 normalisations** : Min-Max, Z-score, Centile
- **ACP** : 2 axe(s) — 98.5% variance
- **3 indices** : équipondéré, ACP, AHP
- **Robustesse** : $\rho_S = 0.996$ (Équi vs AHP)

Limites

Données simulées · Poids AHP subjectifs · Pas de panel

Réponse à la question

Le classement **ne dépend pas** des choix méthodologiques : $\rho_S > 0,99$, variation max. de **1 rang**.

⇒ Le gradient Nord-Ouest / Sud-Est prime sur les choix techniques.

Merci pour votre attention !

Questions & Discussion

ENSAE Dakar — ISEP2 / 2025-2026 · Traitement Statistique avec R

expose06DibaBoye2026ENSAE